Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

Факультет «Информатика и системы управления»
Кафедра ИУ5 «Системы обработки информации и управления»

Отчет по курсовой работе
Сравнительный анализ GradientBoosting и CatBoost на примере датасета Human Resources
по дисциплине «Машинное обучение»

Выполнил:
Кондратьев Максим
05.06.2019

Проверил:
к.т.н., доц., Ю. Е. Гапанюк
подпись, дата

Москва, 2019 г.

Задача:

На основе датасета Human Resources https://www.kaggle.com/rhuebner/human-resources-data-set провести сравнительный анализ двух схем ансамблевых моделей CatBoost и scikit learn GradientBoosting для решения задачи регрессии. Провести разведочный анализ данных, выбор необходимых признаков для каждой из моделей, корреляционный анализ. Выбрать необходимые метрики, построить базовое решение, провести подбор гиперпараметров моделей. Сформировать вывод о качестве построенных моделей на основе выбранных метрик.

Содержание:

1. Подготовительный этап. Чтение и анализ данных
2. Отбор параметров датасета. Кодирование категориальных параметров. Исследование и обработка данных.
3. Построение модели CatBoostRegressor. Подбор параметров. Построение кривой обучения и валидации на основе лучшей модели.
4. Демонстрация результатов модели CatBoostRegressor.
5. Исследование и обработка данных.
6. Построение модели GradientBoostingRegressor. Подбор параметров. Построение кривой обучения и валидации на основе лучшей модели.
7. Демонстрация результатов модели GradientBoostingRegressor.
8. Вывод. Сравнение двух моделей на основе выбранных метрик. Сравнение моделей по времени обучения и удобству использования.

Введение:

CatBoost — открытая программная библиотека разработанная компанией Яндекс и реализующая уникальный патентованный алгоритм построения моделей машинного обучения, использующий одну из оригинальных схем градиентного бустинга. Основное API для работы с библиотекой реализовано для языка Python, также существует реализация для языка программирования R.

18 июля 2017 года CatBoost была открыта для свободного доступа на GitHub компанией Яндекс под свободной лицензией Apache 2.0. CatBoost является системой машинного обучения, использующая одну из оригинальных схем градиентного бустинга. Сравнивая CatBoost с подобными системами машинного обучения компаний Google (TensorFlow) и Microsoft (LightGBM), руководитель разработки систем машинного обучения «Яндекса» Анна Вероника Дорогуш отметила, что Google TensorFlow решает другой класс задач, эффективно анализируя однородные данные — например изображения. А *«CatBoost работает с данными разной природы и может быть использован в связке с TensorFlow и другими алгоритмами машинного обучения в зависимости от конкретных задач»*. У Microsoft LightGBM российская разработка выигрывает по качеству, что демонстрирует таблица тестов с общепринятыми в машинном обучении сравнениями, но пока проигрывает в скорости — что Яндекс обещает исправить.

В качестве датасета для исследования данной технологии я решил взять набор данных, в котором наблюдается преобладание категориальных параметров над числовыми. В качестве «эталона» я решил сравнить показатели модели CatBoost со стандартным градиентным бустингом модуля scikit learn.

Основная часть:

Целью курсовой работы является создание эффективной модели, предсказывающей уровень оплаты работника на основе его характеристик (пола, возраста, эффективности работы, региона проживания, расы, должности, возраста и т. д.). Для решения данной задачи регрессии необходимо провести разведочный анализ данных, отобрать необходимые признаки, провести их обработку для каждой из моделей. Также необходимо выбрать метрики и подобрать параметры для моделей, после чего проанализировать результаты и сделать вывод о качестве построенных моделей.

Процесс решения поставленной задачи отображен в виде исходного кода и экранных форм выполнения программы в сервисе Google Colab:

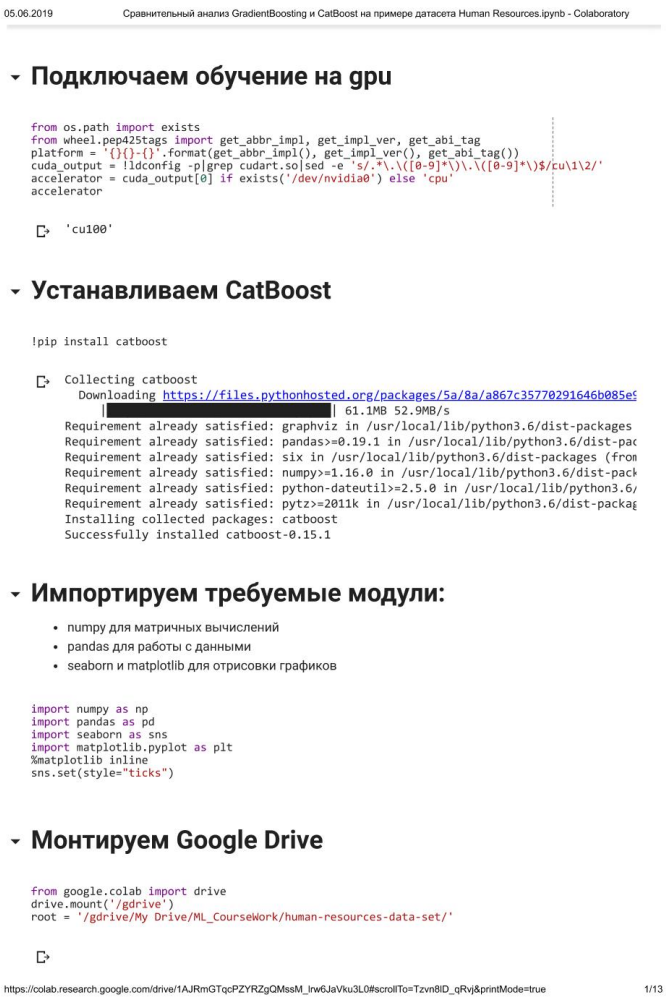
05.06.2019 Сравнительный анализ GradientBoosting и CatBoost на примере датасета Human Resources.ipynb - Colaboratory

Подключаем обучение на gpu

```
from os.path import exists
from wheel.pep425tags import get_abbr_impl, get_impl_ver, get_abi_tag
platform = '{}{}-{}'.format(get_abbr_impl(), get_impl_ver(), get_abi_tag())
cuda_output = !ldconfig -p|grep cudart.so|sed -e 's/.*\.\([0-9]*\)\.\([0-9]*\)$/cu\1\2/'
accelerator = cuda_output[0] if exists('/dev/nvidia0') else 'cpu'
accelerator
```

```
'cu100'
```

Устанавливаем CatBoost

```
!pip install catboost
```

```
Collecting catboost
  Downloading https://files.pythonhosted.org/packages/5a/8a/a867c35770291646b085e6
     |████████████████████████████████| 61.1MB 52.9MB/s
Requirement already satisfied: graphviz in /usr/local/lib/python3.6/dist-packages
Requirement already satisfied: pandas>=0.19.1 in /usr/local/lib/python3.6/dist-pac
Requirement already satisfied: six in /usr/local/lib/python3.6/dist-packages (from
Requirement already satisfied: numpy>=1.16.0 in /usr/local/lib/python3.6/dist-pack
Requirement already satisfied: python-dateutil>=2.5.0 in /usr/local/lib/python3.6/
Requirement already satisfied: pytz>=2011k in /usr/local/lib/python3.6/dist-packag
Installing collected packages: catboost
Successfully installed catboost-0.15.1
```

Импортируем требуемые модули:

- numpy для матричных вычислений
- pandas для работы с данными
- seaborn и matplotlib для отрисовки графиков

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

Монтируем Google Drive

```
from google.colab import drive
drive.mount('/gdrive')
root = '/gdrive/My Drive/ML_CourseWork/human-resources-data-set/'
```

https://colab.research.google.com/drive/1AJRmGTqcPZYRZgQMssM_Irw6JaVku3L0#scrollTo=Tzvn8ID_qRvj&printMode=true 1/13

```
Go to this URL in a browser: https://accounts.google.com/o/oauth2/auth?client_id=9

Enter your authorization code:
··········
Mounted at /gdrive
```

Считываем датасет в pd.DataFrame из .csv файла

Проводим исследование и обработку данных. Обнаруживаем множество категориальных фич, которые требуется перевести в числовые для большинства моделей.

```
hr_stats = pd.read_csv(root+'HRDataset_v9.csv')
hr_stats.head()
```

	Employee Name	Employee Number	MarriedID	MaritalStatusID	GenderID	EmpStatus_ID	Dep
0	Brown, Mia	1103024456	1	1	0	1	
1	LaRotonda, William	1106026572	0	2	1	1	
2	Steans, Tyrone	1302053333	0	0	1	1	
3	Howard, Estelle	1211050782	1	1	0	1	
4	Singh, Nan	1307059817	0	0	0	1	

```
hr_stats.isna().sum()
```

```
Employee Name            0
Employee Number          0
MarriedID                0
MaritalStatusID          0
GenderID                 0
EmpStatus_ID             0
DeptID                   0
Perf_ScoreID             0
Age                      0
Pay Rate                 0
State                    0
Zip                      0
DOB                      0
Sex                      0
```

```
hr_stats.describe()
```

	Employee Number	MarriedID	MaritalStatusID	GenderID	EmpStatus_ID	Dep
count	3.100000e+02	310.000000	310.000000	310.000000	310.000000	310.000
mean	1.199745e+09	0.396774	0.809677	0.429032	2.396774	4.606
std	1.829600e+08	0.490019	0.944702	0.495738	1.795533	1.082
min	6.020003e+08	0.000000	0.000000	0.000000	1.000000	1.000
25%	1.101024e+09	0.000000	0.000000	0.000000	1.000000	5.000
50%	1.203032e+09	0.000000	1.000000	0.000000	1.000000	5.000
75%	1.378814e+09	1.000000	1.000000	1.000000	5.000000	5.000

```
for col in hr_stats.columns:
  print(col, ": Тип - ", hr_stats[col].dtype, 'Уникальных значений -', hr_stats[col].nun
```

```
Employee Name : Тип -  object Уникальных значений - 310
Employee Number : Тип -  int64 Уникальных значений - 309
MarriedID : Тип -  int64 Уникальных значений - 2
MaritalStatusID : Тип -  int64 Уникальных значений - 5
GenderID : Тип -  int64 Уникальных значений - 2
```

Функции для кодирования категориальных параметров

```
DOB : Тип -  object Уникальных значений - 306
```

```
from datetime import datetime

def date_replacement(date_col):
  year = []
  month = []
  day = []
  for e in date_col:
    date = datetime.strptime(e, '%m/%d/%Y')
    year.append(date.year)
    month.append(date.month)
    day.append(date.day)
  return pd.DataFrame(np.array([year, month, day]).T, columns=['year', 'month', 'day'])


def ohe(cat_col):
  return pd.get_dummies(cat_col, columns = cat_col.unique())


from sklearn import preprocessing

def le(cat_col):
  encoder = preprocessing.LabelEncoder()
  le_col= pd.DataFrame(encoder.fit_transform(cat_col), columns=[cat_col.name])
  return le_col


def col_del(data, cols):
  for col in cols:
    try:
      del data[col]
      print("Столбец ", col, " удален")
    except:
      print("Столбец ", col, " не найден")
```

Исследование и обработка данных

В качестве данных для предсказания уровня оплаты человека с помощью модели CatBoost я выбрал основные категориальные фичи моего датасета, вкупе с небольшим количеством численных параметров.

Для обычного градиентного бустинга я использую те же самые данные, но вынужден провести кодирование категориальных.

```
gradboost_cat_features = ['State', 'CitizenDesc', 'Hispanic/Latino', 'RaceDesc', 'Date o
gradboost_num_features = ['MarriedID', 'MaritalStatusID', 'GenderID', 'EmpStatus_ID', 'D
                          'Age', 'Pay Rate', 'Days Employed']
catboost_cat_features = ['Sex', 'MaritalDesc', 'Employment Status', 'Department', 'Perfo
                         'State', 'CitizenDesc', 'Hispanic/Latino', 'RaceDesc', 'Date of
catboost_num_features = ['MarriedID', 'Age', 'Pay Rate', 'Days Employed']
```

```
Num_hr_stats_ohe = hr_stats[gradboost_cat_features+gradboost_num_features].copy()
Num_hr_stats_le = hr_stats[gradboost_cat_features+gradboost_num_features].copy()
Cat_hr_stats = hr_stats[catboost_cat_features + catboost_num_features].copy()
```

В качестве метода кодирование категорий я выбрал LabelEncoding, т.к. OneHotEncoding слишком сильно увеличивает количество параметров за счет большого количества вариативных значений в столбцах

```
col_del(Num_hr_stats_le, gradboost_cat_features)
col_del(Num_hr_stats_ohe, gradboost_cat_features)
col_del(Cat_hr_stats, ['Date of Hire'])

date = date_replacement(hr_stats['Date of Hire'])
Num_hr_stats_le['Year of Hire'] = date['year']
Num_hr_stats_ohe['Year of Hire'] = date['year']
Cat_hr_stats['Year of Hire'] = date['year']
Num_hr_stats_le['Month of Hire'] = date['month']
Num_hr_stats_ohe['Month of Hire'] = date['month']
Cat_hr_stats['Month of Hire'] = date['month']
Num_hr_stats_le['Day of Hire'] = date['day']
Num_hr_stats_ohe['Day of Hire'] = date['day']
Cat_hr_stats['Day of Hire'] = date['day']

for col in gradboost_cat_features:
  if col!='Date of Hire':
    Num_hr_stats_ohe = pd.concat([Num_hr_stats_ohe, ohe(hr_stats[col])], axis=1)
    Num_hr_stats_le[col] = le(hr_stats[col]).values
```

```
Столбец State удален
Столбец CitizenDesc удален
Столбец Hispanic/Latino удален
Столбец RaceDesc удален
Столбец Date of Hire удален
Столбец Reason For Term удален
Столбец Position удален
Столбец Employee Source удален
Столбец State удален
Столбец CitizenDesc удален
Столбец Hispanic/Latino удален
Столбец RaceDesc удален
Столбец Date of Hire удален
Столбец Reason For Term удален
Столбец Position удален
Столбец Employee Source удален
Столбец Date of Hire удален
```

```
print(Num_hr_stats_ohe.shape, Num_hr_stats_le.shape)
```

```
(310, 121) (310, 19)
```

После кодирования, осмотрим распределения и попробуем найти закономерности в данных

На графике видно, что часть данных имеет довольно равномерное распределение, но часть данных представлена в основном одним типом значений. При этом явных закономерностей обнаружить не удалось.

```
sns.pairplot(Num_hr_stats_le)
```

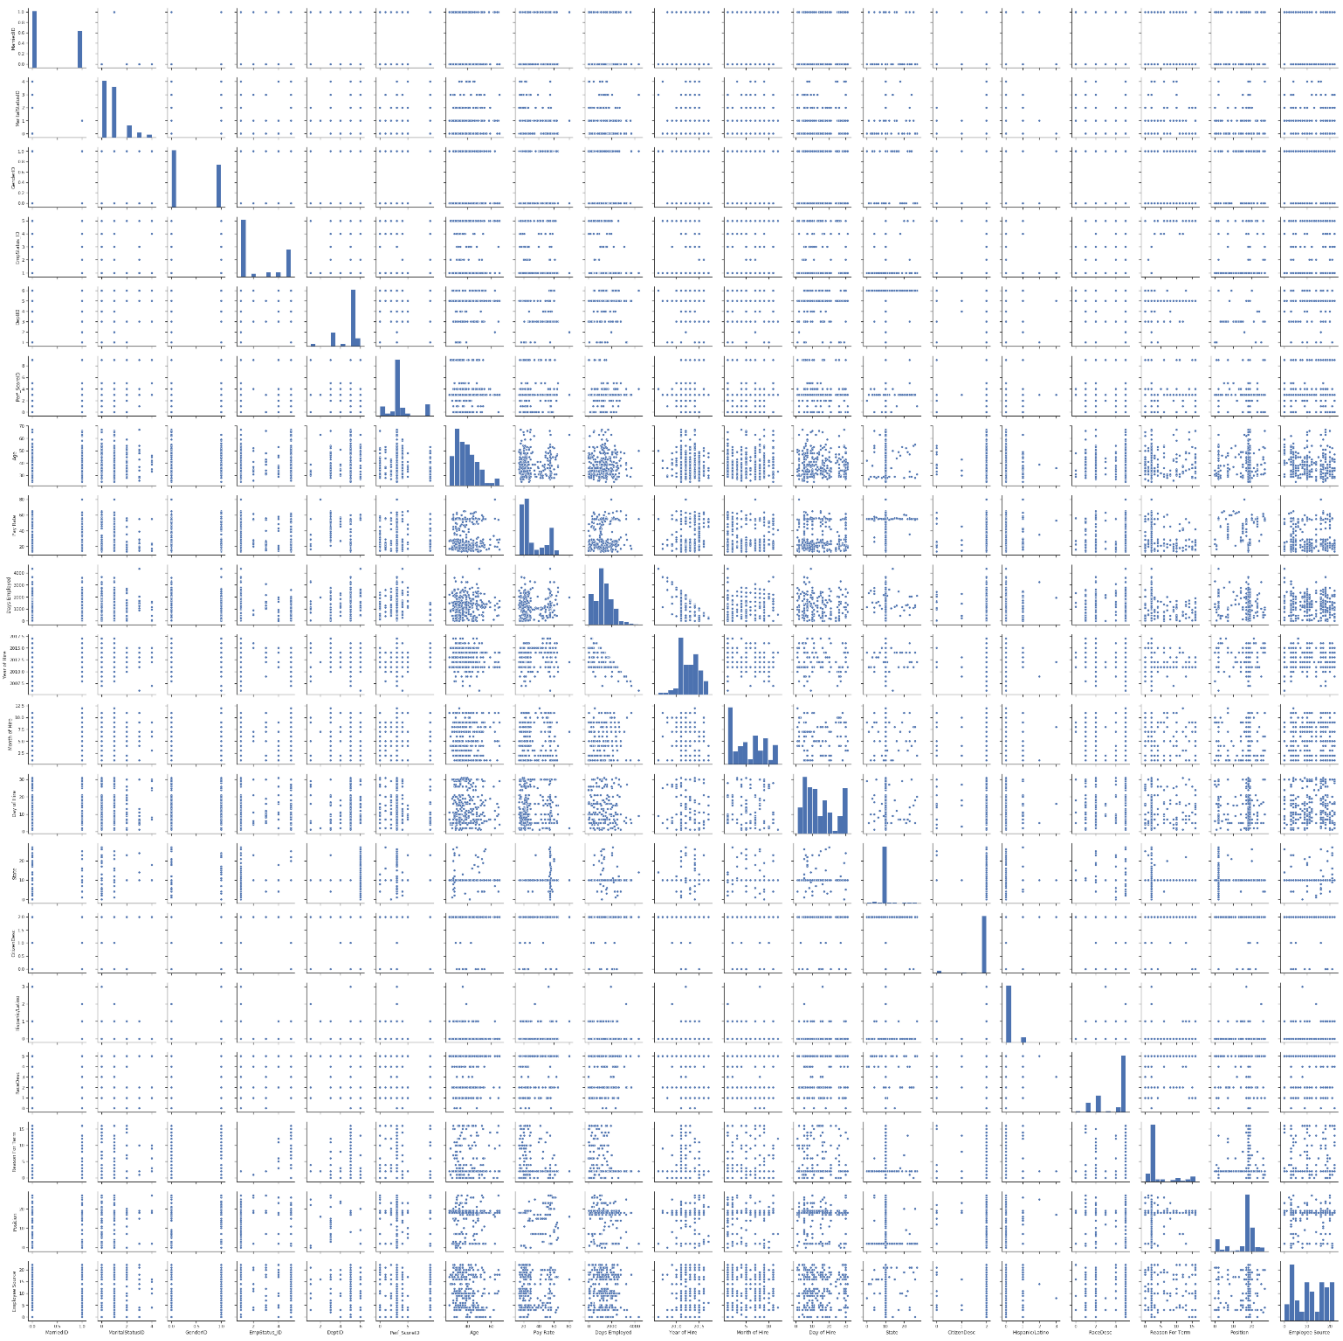

Благодаря корреляционной матрице мы видим, что данные слабо коррелируют за исключением пары отрицательно коррелирующих параметров и корреляции между статусом работы и причинами ухода, т.к. она отсутствует у работающих сотрудников.

```
fig, ax = plt.subplots(figsize=(15,15))
sns.heatmap(Num_hr_stats_le.corr())
```

CatBoost

Без подбора параметров

```
y = Cat_hr_stats['Pay Rate']
X = Cat_hr_stats.copy()
col_del(X, ['Pay Rate'])
```

```
Столбец  Pay Rate  удален
```

```
cat_index = []
i=0
for t in X.dtypes:
  if t=='O':
    cat_index.append(i)
  i+=1
print(len(cat_index), cat_index)
```

```
12 [0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11]
```

```
from catboost import CatBoostRegressor, Pool
from sklearn.model_selection import train_test_split
from sklearn.metrics import r2_score, mean_squared_error, max_error
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

```
train_pool = Pool(X_train, y_train, cat_features = cat_index)
eval_pool =  Pool(X_test, y_test, cat_features = cat_index)
test_pool = Pool(X_test, cat_features = cat_index)
```

```
params = {'iterations': None, 'task_type': "GPU", 'learning_rate': None, 'l2_leaf_reg': N
model = CatBoostRegressor(**params)

model.fit(train_pool, eval_set = eval_pool, logging_level='Verbose', metric_period = 100)
```

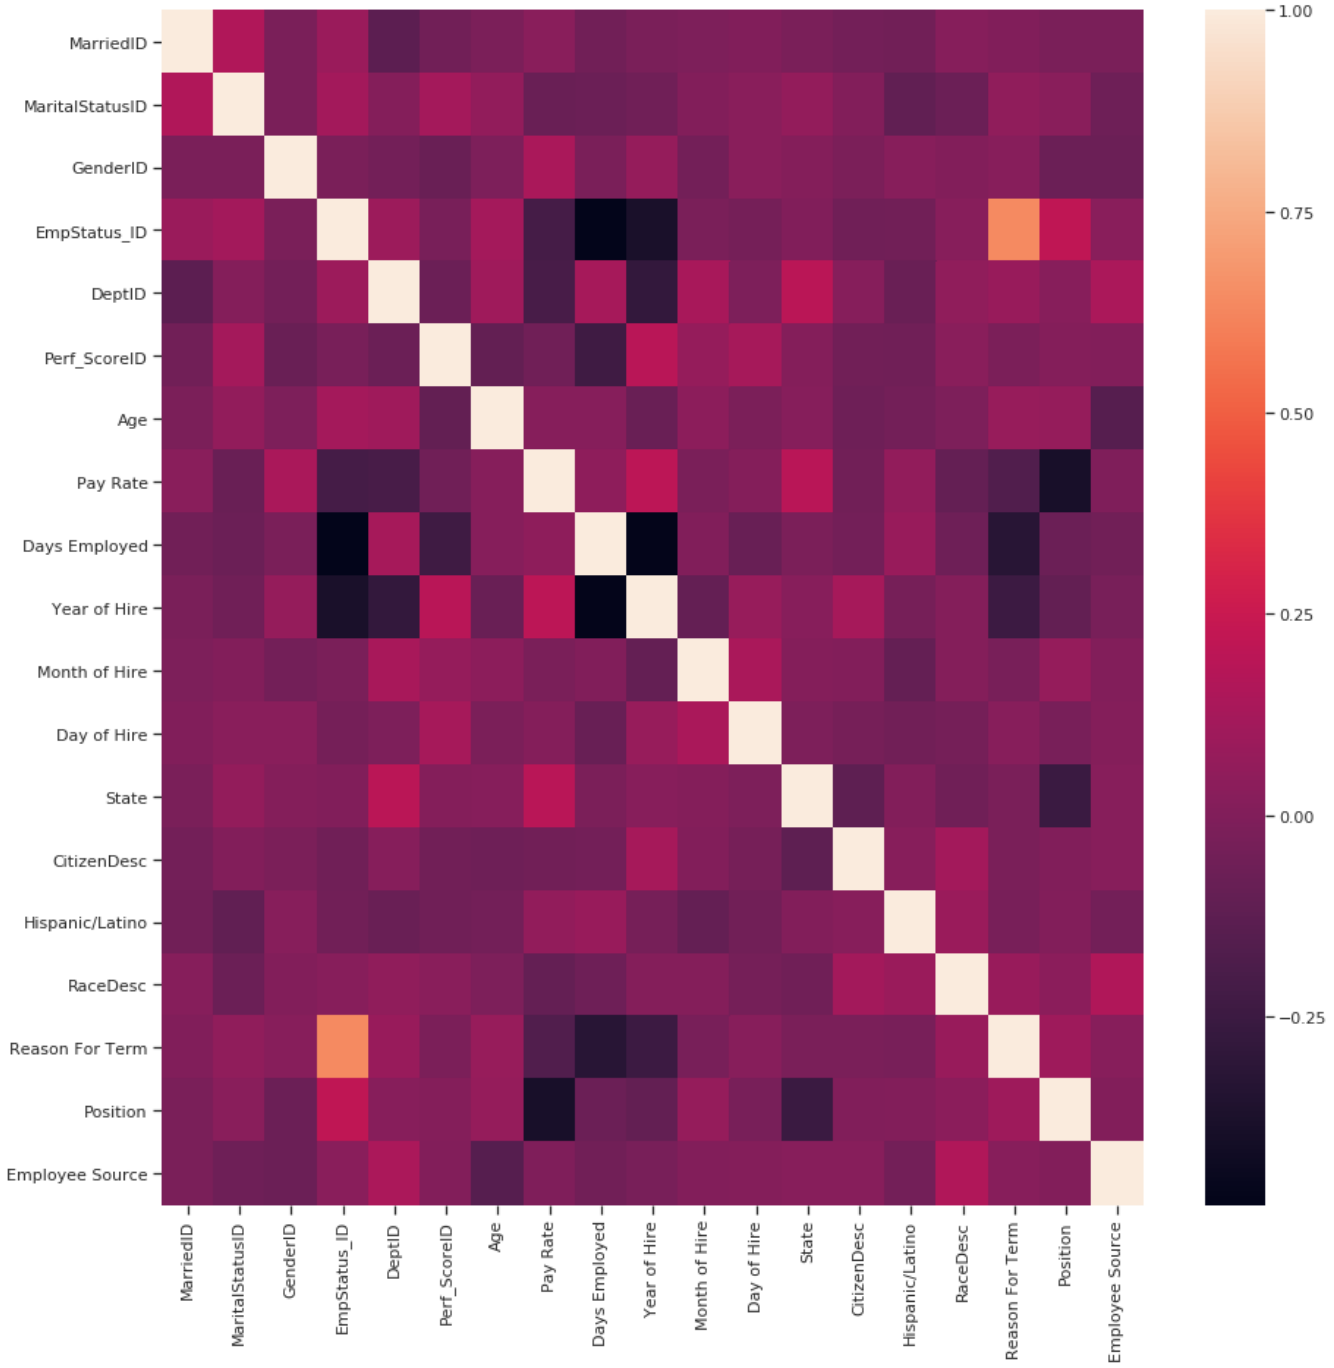
MarriedID
MaritalStatusID
GenderID
EmpStatus_ID
DeptID
Perf_ScoreID
Age
Pay Rate
Days Employed
Year of Hire
Month of Hire
Day of Hire
State
CitizenDesc
Hispanic/Latino
RaceDesc
Reason For Term
Position
Employee Source
1.00
0.75
0.50
0.25
0.00
−0.25

```
0:      learn: 34.0742193       test: 33.5555442        best: 33.5555442 (0)    tc
100:    learn: 7.7747055        test: 9.6680989 best: 9.6680989 (100)   total: 3.2
200:    learn: 6.3211294        test: 8.4774643 best: 8.4774643 (200)   total: 6.2
300:    learn: 5.7302527        test: 8.0589109 best: 8.0589109 (300)   total: 9.1
400:    learn: 5.3407989        test: 7.8308358 best: 7.8308358 (400)   total: 12s
500:    learn: 4.9325701        test: 7.5968775 best: 7.5968775 (500)   total: 14.
```

```
y_pred = model.predict(test_pool)
print('R2:', r2_score(y_test, y_pred))
print('RMSE:', model.score(X_test, y_test))
print('Max_error:', max_error(y_test, y_pred))
```

```
R2: 0.7973743292512916
RMSE: 7.099443755943134
Max_error: 22.41703013729782
```

Подбор параметров

```
def CB_GridSearch(X, y, cat_index):
    res=[]
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state
    train_pool = Pool(X_train, y_train, cat_features = cat_index)
    eval_pool =  Pool(X_test, y_test, cat_features = cat_index)
    test_pool = Pool(X_test, cat_features = cat_index)
    params = {'iterations': [1000, 3500, 7000],
          'learning_rate': [0.003, 0.01, 0.03],
          'l2_leaf_reg': [0, 0.01, 0.1, 1],
          'random_seed': [42]}
    for i in params['iterations']:
        for lr in params['learning_rate']:
            for l2_reg in params['l2_leaf_reg']:
                for rs in params['random_seed']:
                    model = CatBoostRegressor(iterations=i, learning_rate = lr, l2_leaf_r
                    model.fit(train_pool, eval_set = eval_pool, silent=True)
                    y_pred = model.predict(test_pool)
                    res.append({'model': model,'i': i, 'lr': lr, 'l2': l2_reg,
                                'r2': r2_score(y_test, y_pred),
                                'rmse': model.score(X_test, y_test),
                                'max_err': max_error(y_test, y_pred)})
    return res
```

```
res = CB_GridSearch(X, y, cat_index)
```

```
max_r = res[0]
for r in res:
  if r['r2']>max_r['r2']:
    max_r = r
print(max_r)
```

```
model': <catboost.core.CatBoostRegressor object at 0x7f0fa4cbbeb8>, 'i': 1000, 'lr'
```

```
def show_result(x, y_true, y_pred):
  X=x['Days Employed']
  plt.figure(figsize=(6, 4))
  x_low = 0.9*min(X)
  x_high = 1.1*max(X)
  x_extended = np.linspace(x_low, x_high, 100)
  plt.xlim(x_low, x_high)
  plt.xlabel('Дней проработано')
  plt.ylabel('Уровень оплаты')
```

```
    plt.scatter(X, y_true,  color='blue')
    plt.scatter(X, y_pred,  color='red')
    plt.legend(('Истинные значения', 'Предсказанные значения'), loc='best')
    plt.title('Предсказание уровня оплаты работника')
    plt.show()
```

```
params = {'iterations': 1000, 'task_type': "GPU", 'learning_rate': 0.03, 'l2_leaf_reg': 
model = CatBoostRegressor(**params)
model.fit(train_pool)
show_result(X_test, y_test, model.predict(test_pool))
```

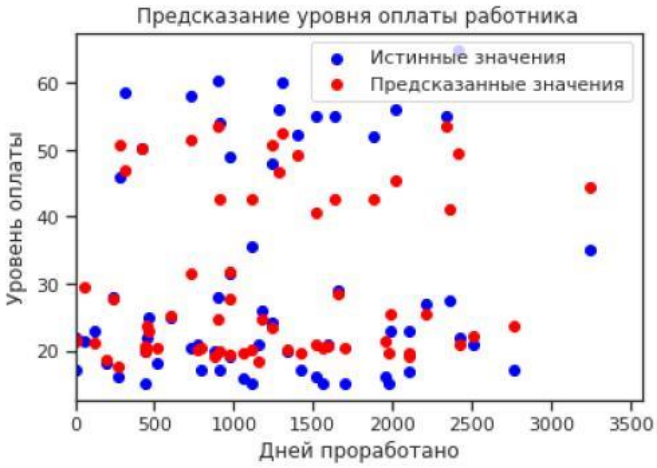

GradientBoostingRegressor

Без подбора параметров

One Hot Encoding

```
y = Num_hr_stats_ohe['Pay Rate']
X = Num_hr_stats_ohe.copy()
col_del(X, ['Pay Rate'])
```

```
Столбец  Pay Rate  удален
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42
```

```
from sklearn.ensemble import GradientBoostingRegressor

gbr = GradientBoostingRegressor(loss='ls', learning_rate=0.1, n_estimators=100,
                                criterion='friedman_mse', max_depth=3, random_state=42,
                                alpha=0.9, verbose=0, validation_fraction=0.1, tol=0.000
gbr.fit(X_train, y_train)
```

```
GradientBoostingRegressor(alpha=0.9, criterion='friedman_mse', init=None,
                          learning_rate=0.1, loss='ls', max_depth=3,
                          max_features=None, max_leaf_nodes=None,
                          min_impurity_decrease=0.0, min_impurity_split=None,
                          min_samples_leaf=1, min_samples_split=2,
                          min_weight_fraction_leaf=0.0, n_estimators=100,
```

```
import math

y_pred = gbr.predict(X_test)
print(r2_score(y_test, y_pred))
print(math.sqrt(mean_squared_error(y_pred, y_test)))
```

```
0.9122283360636667
4.672553212576529
```

Label Encoding

```
y = Num_hr_stats_le['Pay Rate']
X = Num_hr_stats_le.copy()
col_del(X, ['Pay Rate'])
```

```
Столбец  Pay Rate  удален
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

```
gbr = GradientBoostingRegressor(loss='ls', learning_rate=0.1, n_estimators=100,
                                criterion='friedman_mse', max_depth=3, random_state=42)
gbr.fit(X_train, y_train)
y_pred = gbr.predict(X_test)
print(r2_score(y_test, y_pred))
print(math.sqrt(mean_squared_error(y_pred, y_test)))
```

```
0.9148671071348414
4.6017792956075345
```

Подбор параметров

Label Encoding показал себя совсем чуть лучше, поэтому применяем данные, обработанные этим методом

```
from sklearn.model_selection import GridSearchCV

gbr_parameters = {'loss' : ['ls'],
                  'learning_rate': [0.01, 0.1, 1],
                  'random_state': [42],
                  'n_estimators': [60, 100, 120],
                  'max_depth': [2, 3, 4, 5]}
model = gbr
cv = ShuffleSplit(n_splits = 30, test_size = 0.2)
grid = GridSearchCV(model, gbr_parameters, cv = cv)
grid.fit(X_train, y_train)
```

```
GridSearchCV(cv=ShuffleSplit(n_splits=30, random_state=None, test_size=0.2, train_
             error_score='raise-deprecating',
             estimator=GradientBoostingRegressor(alpha=0.9,
                                                 criterion='friedman_mse',
                                                 init=None, learning_rate=0.1,
                                                 loss='ls', max_depth=3,
                                                 max_features=None,
                                                 max_leaf_nodes=None,
                                                 min_impurity_decrease=0.0,
                                                 min_impurity_split=None,
                                                 min_samples_leaf=1,...
                                                 n_iter_no_change=None,
                                                 presort='auto',
                                                 random_state=42, subsample=1.0,
                                                 tol=0.0001,
                                                 validation_fraction=0.1,
                                                 verbose=0, warm_start=False),
             iid='warn', n_jobs=None,
             param_grid={'learning_rate': [0.01, 0.1, 1], 'loss': ['ls'],
                         'max_depth': [2, 3, 4, 5],
```

```
print(grid.best_params_)
```

```
{'learning_rate': 0.1, 'loss': 'ls', 'max_depth': 2, 'n_estimators': 60, 'random_s
```

```
gbr = GradientBoostingRegressor(loss='ls', learning_rate=0.1, n_estimators=60,
                                criterion='friedman_mse', max_depth=2, random_state=42)
gbr.fit(X_train, y_train)
y_pred = gbr.predict(X_test)
print(r2_score(y_test, y_pred))
print(math.sqrt(mean_squared_error(y_pred, y_test)))
```

```
0.8828446801785004
5.398313439154697
```

```
from sklearn.model_selection import learning_curve
from sklearn.model_selection import ShuffleSplit

def plot_learning_curve(estimator, title, X, y, ylim=None, cv=None, n_jobs=None, train_s:
    plt.figure()
    plt.title(title)
    if ylim is not None:
        plt.ylim(*ylim)
    plt.xlabel("Training examples")
    plt.ylabel("Score")
    train_sizes, train_scores, test_scores = learning_curve(
        estimator, X, y, cv=cv, n_jobs=n_jobs, train_sizes=train_sizes)
    train_scores_mean = np.mean(train_scores, axis=1)
    train_scores_std = np.std(train_scores, axis=1)
    test_scores_mean = np.mean(test_scores, axis=1)
    test_scores_std = np.std(test_scores, axis=1)
    plt.grid()

    plt.fill_between(train_sizes, train_scores_mean - train_scores_std,
                     train_scores_mean + train_scores_std, alpha=0.1,
                     color="r")
    plt.fill_between(train_sizes, test_scores_mean - test_scores_std,
                     test_scores_mean + test_scores_std, alpha=0.1, color="g")
    plt.plot(train_sizes, train_scores_mean, 'o-', color="r",
             label="Training score")
    plt.plot(train_sizes, test_scores_mean, 'o-', color="g",
             label="Cross-validation score")

    plt.legend(loc="best")
    return plt
```

```
title = "Кривая обчения"
estimator = GradientBoostingRegressor(**(grid.best_params_))
cv = ShuffleSplit(n_splits=30, test_size=0.2, random_state=42)
plot_learning_curve(estimator, title, X, y, cv=cv, n_jobs=4)

plt.show()
```


```
from sklearn.model_selection import validation_curve
from sklearn.metrics import make_scorer

def val_curve(X, y, model):
  X, y = X, y

  param_range = np.logspace(-6, -1, 5)
  cv = ShuffleSplit(n_splits=30, test_size=0.2, random_state=42)
  r2_scorer = make_scorer(r2_score)
  train_scores, test_scores = validation_curve(model, X, y, param_name="learning_rate", p
  train_scores_mean = np.mean(train_scores, axis=1)
  train_scores_std = np.std(train_scores, axis=1)
  test_scores_mean = np.mean(test_scores, axis=1)
  test_scores_std = np.std(test_scores, axis=1)

  plt.title("Validation Curve")
  plt.xlabel("learning_rate")
  plt.ylabel("R2 Score")
  plt.ylim(0.0, 1.1)
  lw = 2
  plt.semilogx(param_range, train_scores_mean, label="Training score",
               color="darkorange", lw=lw)
  plt.fill_between(param_range, train_scores_mean - train_scores_std,
                   train_scores_mean + train_scores_std, alpha=0.2,
                   color="darkorange", lw=lw)
  plt.semilogx(param_range, test_scores_mean, label="Cross-validation score",
               color="navy", lw=lw)
  plt.fill_between(param_range, test_scores_mean - test_scores_std,
                   test_scores_mean + test_scores_std, alpha=0.2,
                   color="navy", lw=lw)
  plt.legend(loc="best")
  plt.show()
```

```
val_curve(X, y, estimator)
```

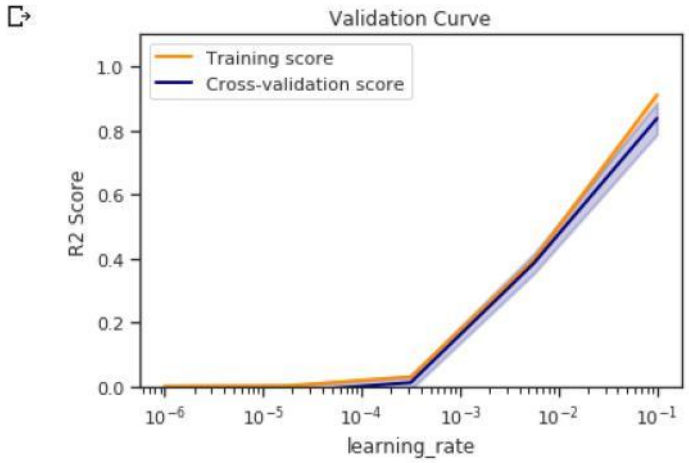


```
show_result(X_test, y_test, y_pred)
```

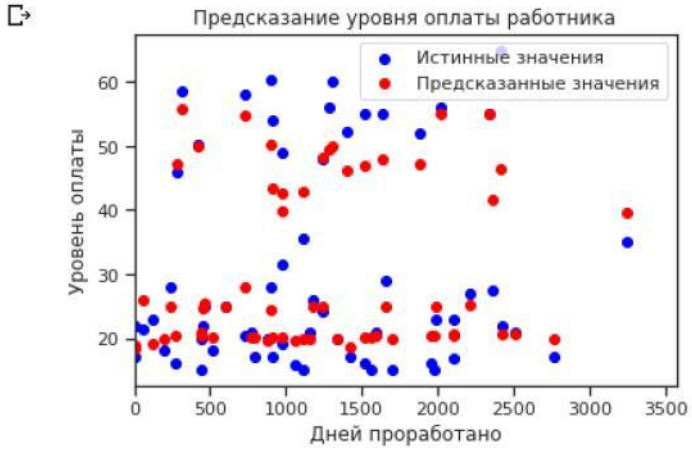

Вывод:

В ходе курсовой работы я решал задачу регрессии - предсказывал уровень оплаты работника, на основе его данных с помощью двух близких по роду ансамблевых моделей - обычного градиентного бустинга и модели компании Yandex - CatBoost.

Умение CatBoost работать с категориальными параметрами "из под капота" - удобная функция, которая упрощает разработку модели, особенно с наборами данных, включающими множество разнородной категориальной информации.

В результате обучения и подбора параметров обоих моделей на одних и тех же наборах параметров лучшим вариантом по точности и времени обучения оказалась модель обычного градиентного бустинга.

Модель CatBoost также имеет конкурирующую точность, но отличается довольно долгим обучением. Также она имеет большой набор гиперпараметров, которые сложно подобрать в рамках курсовой работы. Таким образом, при должной настройке, данный алгоритм наверняка может показать себя с лучшей стороны.

Список литературы:

1. https://scikit-learn.org
2. https://catboost.ai
3. https://ru.wikipedia.org
4. https://github.com/ugapanyuk/ml_course